

Rapport EI Mondor

Groupe 2

Mohamed Reda Boussaadi, Ilyas Et-tabouti, Gilles-Roberto Belinga, Antonin Biarrotte, Aloïs Jose

6 juin 2025

1 introduction

Le diagnostic différentiel entre le CHC (carcinome hépatocellulaire) et le CCK (cholangiocarcinome) reste un enjeu critique en imagerie médicale. Grâce aux données radiomiques issues d'IRM multiphases, ce travail vise à explorer l'apport de techniques de traitement de données, de sélection de variables et d'algorithmes d'apprentissage automatique pour affiner la précision des prédictions. En combinant tests statistiques, équilibrage des classes et modèles comme Random Forest, Lasso ou XGBoost, nous cherchons à construire un classifieur performant et interprétable, capable d'assister les radiologues dans leurs décisions.

2 Pré-traitement de données

Le pré-traitement des données a consisté en plusieurs étapes essentielles visant à nettoyer et structurer les données avant leur utilisation en apprentissage automatique. Tout d'abord, les variables non numériques, les colonnes de diagnostics, ainsi que celles contenant uniquement des valeurs nulles ont été supprimées, afin de ne conserver que les informations exploitables. Ensuite, les patients présentant des phases mixtes ont été écartés, tout comme ceux ne disposant que de deux phases, car jugés insuffisants pour l'analyse temporelle. Afin d'améliorer la cohérence et l'équilibre du jeu de données, les différentes phases des patients restants ont été fusionnées. Enfin, un regroupement a été effectué pour ne conserver qu'une seule ligne par patient, synthétisant l'ensemble des informations disponibles de manière consolidée.

3 Sélection des variables

Cette étape consiste à réduire la taille des données en identifiant les variables les plus discriminantes pour la classification. En effet, dans un contexte médical, c'est bien pour le praticien à se concentrer uniquement sur les variables les plus pertinentes, plutôt que d'analyser l'ensemble des variables disponibles, souvent nombreuses et coûteuses à obtenir. Cette sélection permet non seulement d'alléger le modèle, mais aussi de guider les médecins vers un diagnostic plus rapide et plus fiable, en mettant en évidence les variables les plus influentes dans la distinction entre CHC et CCK.

3.1 Test par permutation

Une première approche pour la sélection des variables explicatives était d'utiliser des tests statistiques. Dans un premier temps, nous avons utilisé des tests statistiques tels que les tests de Student et de Wilcoxon (hypothèse de loi normale, ou de distribution symétrique), mais les histogrammes des variables explicatives obtenues ne vérifiaient presque jamais les hypothèses considérées. Ainsi, nous nous sommes tournés vers un test statistique non paramétrique : le test de permutation. Ce test se base sur le test de Student mais ne nécessite pas d'hypothèse préliminaire. On calcule, pour chaque permutation de valeur de la variable qui nous intéresse, la statistique de Student associée. Une fois toutes les statistiques obtenues, elles forment une distribution empirique. Cette distribution nous permet de mesurer la p-valeur et de continuer notre démarche. Il est cependant important de noter que le nombre de permutations peut très vite être astronomique et donc le calcul de toutes les permutations est impossible. Donc, nous avons pris un nombre réduit de permutations (de l'ordre de quelques dizaines de milliers) de manière aléatoire parmi toutes celles possibles. Nous obtenons principalement : des variables liées à l'énergie. On peut ensuite remarquer que ces variables sont souvent plus élevées pour le cancer de type CHC. des variables liées à la forme de la tumeur. Elles peuvent mesurer des valeurs en lien avec le volume, la surface, ... Ces variables peuvent être plus élevées pour le cancer de type CHC car son volume est généralement moins diffus que le cancer CCK. des variables liées à l'image radiomique obtenue (contraste, intensité du niveau de gris). De la même manière, le cancer minoritaire CCK paraît plus hétérogène donc le contraste est plus élevé. Parallèlement, l'intensité du niveau de gris est plus élevée pour le cancer CHC car justement il est homogène.




FIGURE 1 – Histogramme d'une variable choisie par le test de Wilcoxon

3.2 Méthode LASSO

Nous avons appliqué la méthode de sélection de variables par LASSO (Least Absolute Shrinkage and Selection Operator). Le modèle de régression LASSO utilisé pour cette étape est présenté en détail dans la section dédiée à l'apprentissage. Les variables retenues à l'issue de cette méthode sont résumées dans le tableau 2

Variables	Descriptions
1 original_shape_Sphericity_PORT	Forme, compacité sphérique
2 original_gldm_DependenceVariance_ART	Variance dépendance (texture)
3 original_firstorder_Skewness_ART	Variance dépendance ART (texture)
4 original_glszm_SmallAreaEmphasis_PORT	Asymétrie intensité
5 original_ngtdm_Coarseness_PORT	Accentuation des petites zones
6 original_firstorder_Skewness_FUSED_VEIN_TARD	Granularité (coarseness)
7 original_gldm_DependenceVariance_FUSED_VEIN_TARD	Asymétrie intensité veine tardive
8 original_gldm_LargeDependenceHighGrayLevelEmphasis_FU...	Variance dépendance veine tardive
9 original_ngtdm_Busyness_FUSED_VEIN_TARD	Grandes zones dépendantes haute intensité
10 original_firstorder_Minimum_ART	Busyness veine tardive (variation locale)
11 original_shape_Flatness_PORT	Intensité minimum ART
12 original_gldm_ClusterShade_ART	Forme aplatissement
13 original_gldm_ClusterShade_PORT	Ombre de cluster GLCM ART (complexité)
14 original_gldm_LargeDependenceHighGrayLevelEmphasis_ART	Grandes zones dépendantes haute intensité ART
15 original_glszm_LargeAreaHighGrayLevelEmphasis_ART	Grandes zones intensité élevée GLSZM ART
16 original_glszm_SmallAreaLowGrayLevelEmphasis_PORT	Petites zones faible intensité GLSZM PORT
17 original_shape_Flatness_FUSED_VEIN_TARD	Aplatissement veine tardive

FIGURE 2 – Les variables sélectionnées par la méthode de LASSO

3.2.1 Test de stabilité des variables sélectionnées

Afin d'évaluer la robustesse des variables sélectionnées par la méthode LASSO, nous avons mis en place un test de stabilité. Une boucle comportant 100 itérations a été implémentée. À chaque itération, un sous-échantillon aléatoire du jeu de données est extrait, et la méthode LASSO est appliquée.

Les variables sélectionnées dans plus de 50 % des cas sont considérées comme stables. Ces variables sont résumées dans le tableau 3

original_shape_Sphericity_PORT
original_firstorder_Skewness_FUSED_VEIN_TARD
original_firstorder_Skewness_ART
original_ngtdm_Busyness_ART
original_gldm_LargeDependenceHighGrayLevelEmphasi...
original_gldm_ClusterShade_PORT
original_ngtdm_Coarseness_PORT
original_gldm_ClusterShade_ART

FIGURE 3 – Les variables stable pour fréq>0.5

3.2.2 interprétation des variables par leur coefficients LASSO

À partir des coefficients issus du modèle LASSO, nous avons extrait les variables présentant une contribution significative à la classification. Les variables associées à un coefficient positif sont interprétées comme favorisant le diagnostic de CHC (carcinome hépatocellulaire), tandis que celles ayant un coefficient négatif sont associées au CCK (cholangiocarcinome).

Les résultats de cette analyse sont résumés dans le tableau 4

variable	coefficient	fav_class
original_shape_Flatness_ART	-15.31312	Favorise CCK
original_shape_Sphericity_PORT	32.98669	Favorise CHC
original_shape_SurfaceVolumeRatio_PORT	-11.41681	Favorise CCK
original_gldm_SmallDependenceLowGrayLevelEmphasis_ART	10.49607	Favorise CHC
original_glszm_LowGrayLevelZoneEmphasis_PORT	33.53585	Favorise CHC
original_ngtdm_Coarseness_PORT	-116.07020	Favorise CCK

FIGURE 4 – les variables avec des coefficients significatifs

3.3 Comparaison

En réalisant la matrice de corrélation entre les données du test de permutation et la variable "Sphericity" trouvée avec la méthode LASSO (figure 5), on peut remarquer que cette dernière est plutôt corrélée avec les variables liées à la forme de la tumeur du test réalisé. Cela est assez rassurant malgré des variables trouvées différentes. On remarque aussi une forte corrélation entre les variables de la méthode du test (entre les énergies et les variables de forme)




FIGURE 5 – les variables avec des coefficients significatifs

4 Déséquilibre des classes

Dans notre jeu de données spécifique, l'objectif est de construire un classificateur capable de prédire la classe d'un patient entre CHC (carcinome hépatocellulaire) et CCK (cholangiocarcinome). Cependant, le principal défi réside dans le fait que la classe CHC est largement majoritaire par rapport à la classe CCK.

Pour éviter que le modèle ne soit biaisé en faveur de la classe majoritaire, nous avons appliqué deux méthodes d'équilibrage des classes : la duplication des exemples de la classe minoritaire et la méthode SMOTE.

4.1 Duplication

La première méthode que nous avons choisie pour équilibrer les classes est la suivante : nous avons dupliqué les patients minoritaires, c'est-à-dire les patients atteints du cancer de type CCK. Concrètement, après avoir séparé nos patients en 70 % d'apprentissage et 30 % de test, nous avons dupliqué les patients atteints du type CCK afin d'obtenir une proportion équilibrée entre les deux types de cancer. Bien entendu, nous faisons attention de dupliquer seulement après avoir séparé nos patients, pour éviter que notre classifieur ne tombe sur le même patient lors de la phase d'apprentissage et de la phase de test.

4.2 Méthode SMOTE

(Synthetic Minority Over-sampling Technique) est une technique de suréchantillonnage qui permet d'équilibrer les classes dans un jeu de données déséquilibré. Elle génère artificiellement de nouveaux exemples pour la classe minoritaire en interpolant des instances existantes à partir de leurs voisins les plus proches, afin de réduire le biais introduit par un déséquilibre important entre classes.




FIGURE 6 – Le principe de SMOT

5 Apprentissage

Dans le cadre de ce projet de classification des types de cancer, nous avons exploré trois approches de modélisation supervisée : la régression logistique avec pénalisation Lasso, la forêt aléatoire (Random Forest), et XG-Boost (Extreme Gradient Boosting). Chaque méthode a ses propres avantages en termes de complexité, d'interprétabilité et de performance.

5.0.1 Régression Logistique avec Lasso

La régression logistique est un modèle linéaire utilisé pour des tâches de classification binaire. Elle repose sur la fonction logistique pour estimer la probabilité qu'une observation appartienne à une classe donnée. Pour améliorer la généralisation et effectuer une sélection automatique de variables, nous ajoutons une pénalisation Lasso (norme L1) sur les coefficients du modèle.

Formulation mathématique

$$\hat{y} = \frac{1}{1 + e^{-\mathbf{x}^\top \boldsymbol{\beta}}}$$

La fonction de coût à minimiser est la suivante :

$$\mathcal{L}(\boldsymbol{\beta}) = - \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] + \lambda \sum_j |\beta_j|$$

où :

- $\mathbf{x}$ est le vecteur des caractéristiques,
- $\boldsymbol{\beta}$ est le vecteur des coefficients,
- λ est le paramètre de régularisation.

5.0.2 Forêt Aléatoire (Random Forest)

La forêt aléatoire est un algorithme d'ensemble qui construit un grand nombre d'arbres de décision à partir d'échantillons bootstrap de l'ensemble de données. Chaque division de chaque arbre est basée sur un sous-ensemble aléatoire de variables. Le résultat final est obtenu par vote majoritaire.

Formulation mathématique

$$\hat{y} = \text{majority_vote}(h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_T(\mathbf{x}))$$

où :

- $h_t(\mathbf{x})$ est la prédiction de l'arbre t ,
- T est le nombre total d'arbres dans la forêt.

Cette méthode permet de réduire la variance du modèle sans augmenter significativement le biais.

5.0.3 XGBoost (Extreme Gradient Boosting)

XGBoost est une méthode de boosting par gradient particulièrement efficace. Elle construit les arbres de décision de manière séquentielle, en corrigeant les erreurs des prédictions précédentes. Ce modèle intègre également une régularisation explicite afin de mieux contrôler la complexité du modèle et éviter le surapprentissage.

Formulation mathématique

La fonction objectif à minimiser est définie par :

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum k = 1^t \Omega(f_k)$$

avec :

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

$$\hat{y}_i^{(t)} = \sum k = 1^t f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F}$$

où :

- $l(y_i, \hat{y}_i^{(t)})$ est la fonction de perte (ex. log loss),
- $\mathcal{F}$ est l'ensemble des arbres possibles,
- f_k est un arbre de décision,
- γ et λ sont des paramètres de régularisation.

5.0.4 Conclusion

Ces trois méthodes offrent des approches complémentaires pour la classification. La régression logistique Lasso est simple et interprétable, la forêt aléatoire est robuste et facile à entraîner, et XGBoost fournit souvent des performances de pointe grâce à son apprentissage séquentiel et régularisé.

5.1 Forêt aléatoire avec duplication

La première méthode de classification que nous avons mise en place est la méthode des forêts aléatoires. Nous avons pour cela utilisé les variables explicatives que nous avons trouvées avec le test de permutation, et nous avons équilibré notre jeu de données avec la méthode de duplication pour avoir en proportion identique des patients atteints du cancer de type CCK et du type CHC. En appliquant ce modèle de forêts à notre jeu de donnée, nous obtenons une précision de près de 81,3%, ce qui est satisfaisant, mais nous observons que les patients atteints du cancer de type CCK semblent sous représentés dans la prédiction : près d'un quart d'entre eux sont prédis comme atteint du cancer de type CHC. Dans la suite de l'étude, nous avons utilisé la méthode LASSO pour la sélection des variables, et la méthode SMOTE pour l'équilibrage.




FIGURE 7 – Matrice de confusion obtenue pour le test des permutations

5.2 Apprentissage binaire (2 classes : CHC, CCK)

Nous avons implémenté trois modèles de classification : Gradient Boosting (GB), Random Forest (RF) et LASSO. Ces modèles ont été testés sur quatre cas distincts :

1. Utilisation de l'ensemble des données sans sélection préalable des variables discriminantes et sans application de la méthode SMOTE.
2. Utilisation de l'ensemble des données sans sélection des variables, avec application de la méthode SMOTE pour équilibrer les classes.
3. Utilisation des données après sélection des variables discriminantes obtenues par la méthode LASSO (cf. section 2), sans application de SMOTE.
4. Utilisation des données avec sélection des variables discriminantes et application de la méthode SMOTE.

Les deux graphiques ci-joints présentent la précision (accuracy) ainsi que l'aire sous la courbe ROC (AUC, *Area Under the Curve*) pour les différents modèles et scénarios testés.




FIGURE 8 – les résultats de la précision et AUC pour les différents cas et modèles

En conclusion, le modèle LASSO appliqué sur l'ensemble des données sans utilisation de la méthode SMOTE a obtenu les meilleures performances, avec une précision de 97 % ainsi qu'une AUC optimale, ce qui souligne l'efficacité de la sélection des variables dans ce contexte.

5.3 Apprentissage multi-classes (3 classes : CHC, CCK, Mixtes)

Initialement, le problème de classification était formulé comme un problème binaire, opposant deux types de cancers. Cependant, afin de mieux exploiter l'ensemble des données disponibles et d'élargir la portée du modèle, il a été nécessaire d'étendre l'approche vers une classification multi-classe, impliquant les trois classes distinctes. Cette extension a exigé l'adaptation des algorithmes utilisés pour qu'ils puissent gérer plus de deux étiquettes, en utilisant par exemple la stratégie *one-vs-rest* (OvR) pour la régression logistique, ou la gestion native du multi-classe dans Random Forest et XGBoost.

Cette adaptation permet désormais au modèle de distinguer plus finement les différents types de cancer en fonction des caractéristiques biologiques observées.




FIGURE 9 – la précision pour

6 Exploitation des Données Radiomiques Multi-Slice

Les études précédentes étaient principalement basées sur le document *radiomiques_globale*, qui fournissait des informations extraites de scans 3D du foie, résumées globalement pour chaque patient. Afin d'approfondir l'analyse et potentiellement améliorer la performance des modèles, nous nous sommes tournés vers le document *radiomique_multislice*. Ce dernier contient des valeurs extraites slice par slice (coupes successives) pour un échantillon des patients, ce qui le rend considérablement plus riche. Il comprend près de 10 000 lignes de données, offrant potentiellement une sélection bien plus fine. L'objectif est donc

de vérifier si cette nouvelle source permet d'améliorer la précision des classifieurs et, plus largement, de déterminer s'il est vraiment nécessaire d'avoir autant de coupes pour poser un diagnostic fiable.

Une première approche pour exploiter ces données consistait à ne sélectionner qu'une seule slice par patient, choisie en maximisant un paramètre donné tel que l'énergie, le contraste ou encore la surface de la région d'intérêt. Cette stratégie visait à conserver une seule observation pertinente par patient tout en simplifiant le jeu de données.




FIGURE 10 – la précision des trois modèles pour différents variables

Comme on peut le voir, bien que les précisions obtenues soient intéressantes, la mesure de l'AUC révèle que cette méthode reste aléatoire, avec des performances proches d'un modèle hasardeux. Cette instabilité indique que la sélection d'une seule coupe ne permet pas de capturer suffisamment d'informations discriminantes.

La deuxième méthode testée a consisté à considérer chaque ligne du fichier comme un patient unique, ce qui revient à traiter chaque slice indépendamment. Cette approche transforme les 10 000 slices en autant d'unités d'analyse, ce qui multiplie considérablement la taille apparente du jeu de données.

```
LASSO AUC: 0.9197251 Accuracy: 0.9032012
Random Forest AUC: 0.9935355 Accuracy: 0.9618902
XGBoost AUC: 0.9940035 Accuracy: 0.9753557
```

FIGURE 11 – Les variables stable pour fréq>0.5

Les résultats sont particulièrement impressionnants en termes de précision et d'AUC. Toutefois, cette approche souffre d'un biais important : des slices très proches (provenant du même patient) peuvent être réparties entre les ensembles d'entraînement et de test, ce qui conduit à un fort effet de sur-apprentissage. Le modèle apprend alors des patterns spécifiques à un patient qu'il retrouve ensuite dans l'ensemble de test, faussant les performances.

Pour pallier ce problème, une dernière stratégie a été testée : effectuer la répartition des données non plus au

niveau des slices, mais au niveau des patients. Cela signifie que l'ensemble de test et l'ensemble d'entraînement contiennent des patients complètement distincts (par exemple, 70% des patients pour l'entraînement, 30% pour le test). Cette séparation garantit une meilleure généralisation et évite les fuites d'information entre les ensembles. Les performances ainsi obtenues sont plus réalistes et co-

LASSO AUC: 0.7927986 Accuracy: 0.817189
Random Forest AUC: 0.7698758 Accuracy: 0.8615859
XGBoost AUC: 0.7894547 Accuracy: 0.8596866

FIGURE 12 – Les variables stable pour fréq>0.5

hérentes avec les résultats des modèles précédents. Cette approche constitue une base plus fiable pour évaluer l'apport réel des données multi-slice dans le cadre du diagnostic automatisé.

7 Conclusion

Ce projet a permis de démontrer que l'utilisation conjointe de méthodes statistiques rigoureuses et de modèles d'apprentissage supervisé améliore significativement la classification des cancers du foie. La meilleure performance a été obtenue en combinant la sélection de variables par permutation et le rééquilibrage via SMOTE, avec une précision allant jusqu'à 81.8%. Ces résultats encouragent le développement d'outils intelligents d'aide au diagnostic basés sur des données radiomiques. L'intégration clinique de ces approches nécessite encore une validation sur de plus larges cohortes.